

分析师:

徐寅

xuyinsh@xyzq.com.cn

S0190514070004

郑兆磊

zhengzhaolei@xyzq.com.cn

S0190520080006

## 西学东渐--海外文献推荐系列之一百二十二

2021年6月17日

## 投资要点

## 报告关键点

在过去的几十年里,风格轮动策略在学术界和市场从业者中越来越受到关注。本次研究引入了创新性的建模方法,并测试其是否能够有效地预测股票市场风格的变化。在本文中,单/多变量逻辑回归模型和几种机器学习模型被用来预测风格的定向转变。同时我们运用统计学指标和经济学指标对其进行评估。分析表明,基于某些因子的单变量逻辑回归模型和几种机器学习模型,例如朴素贝叶斯、装袋算法 Bagging、贝叶斯广义线性模型 GLM、判别分析模型和 KNN 模型,可以有效提高预测的准确性并能够由此构建出表现较好的投资策略。

## 相关报告

《西学东渐--海外文献推荐系列之一百二十一》

《西学东渐--海外文献推荐系列之一百二十》

《西学东渐--海外文献推荐系列之一百一十九》

- 西学东渐,是指从明朝末年到近代,西方学术思想向中国传播的历史过程。西学东渐不仅推动了中国在科学技术和思想文化方面的发展,也有力地促进了社会与政治的大变革。在今天,西学东渐仍有其重要的现实意义。作为 A 股市场上以量化投资为研究方向的卖方金融工程团队,在平日的工作中,常常深感海外相关领域的研究水平之高、内容之新。而这也促使我们通过大量的材料阅读,去粗取精,将认为最有价值的海外文献呈现在您的面前!
- 在过去的几十年里,风格轮动策略在学术界和市场从业者中越来越受到关注。本次研究引入了创新性的建模方法,并测试其是否能够有效地预测股票市场风格的变化。在本文中,单/多变量逻辑回归模型和几种机器学习模型被用来预测风格的定向转变。同时我们运用统计学指标和经济学指标对其进行评估。分析表明,基于某些因子的单变量逻辑回归模型和几种机器学习模型,例如朴素贝叶斯、装袋算法 Bagging、贝叶斯广义线性模型 GLM、判别分析模型和 KNN 模型,可以有效提高预测的准确性并能够由此构建出表现较好的投资策略。

风险提示:文献中的结果均由相应作者通过历史数据统计、建模和测算完成,在政策、市场环境发生变化时模型存在失效的风险。

请务必阅读正文之后的信息披露和重要声明



## 目录

1、引言 .....	3 -
2、文献综述 .....	5 -
3、数据 .....	8 -
4、实证设计和分析 .....	9 -
4.1、基于统计学指标的预测性能评估 .....	10 -
4.2、基于实时交易策略的经济表现评估 .....	14 -
5、总结 .....	19 -
图表 1、统计学表现评估：单变量逻辑回归模型和机器学习-标普 500 利差 ..	11 -
图表 2、统计学表现评估：单变量逻辑回归模型和机器学习-罗素 1000 利差	12 -
图表 3、统计学表现评估：单变量逻辑回归模型和机器学习-规模利差 .....	13 -
图表 4、统计学表现评估：单变量逻辑回归模型和机器学习-BAB 利差 .....	14 -
图表 5、经济学表现评估：单变量逻辑回归模型和机器学习-标普 500 利差 ..	15 -
图表 6、经济学表现评估：单变量逻辑回归模型和机器学习-罗素 1000 利差	16 -
图表 7、部分风格策略表现 .....	17 -
图表 8、经济学表现评估：单变量逻辑回归模型和机器学习-规模利差 .....	18 -
图表 9、经济学表现评估：单变量逻辑回归模型和机器学习-BAB 利差 .....	19 -
图表 A1、预测变量集 .....	21 -

## 报告正文

## 重新审视风格轮动

## 文献来源:

Galakis, J., Vrontos, I., & Vrontos, S., Style Rotation Revisited. The Journal of Financial Data Science, 2021.

## 推荐原因:

在过去的几十年里,风格轮动策略在学术界和市场从业者中越来越受到关注。本次研究引入了创新性的建模方法,并测试其是否能够有效地预测股票市场风格的变化。在本文中,单/多变量逻辑回归模型和几种机器学习模型被用来预测风格的定向转变。同时我们运用统计学指标和经济学指标对其进行评估。分析表明,基于某些因子的单变量逻辑回归模型和几种机器学习模型,例如朴素贝叶斯、装袋算法 Bagging、贝叶斯广义线性模型 GLM、判别分析模型和 KNN 模型,可以有效提高预测的准确性并能够由此构建出表现较好的投资策略。

## 关键词:

风格投资、股票分析和估值、大数据/机器学习、表现度量

## 1、引言

在过去的 50 年里,实证研究大都集中在找寻能解释预期收益变化的因子。自 1970 年代初以来,学者们在资产定价的文献中已构建出大量不同的因子,但只有少数能够在投资中长期地获得高于平均水平收益的因子才能引起学术界和市场从业者的一致关注。更具体地说,许多学术研究已经详细表明:基于价值、规模和动量相关特征的投资组合具有优势。随着时间的推移,这些因子已成为评估投资业绩或经理能力的基准。

长期以来,人们普遍认为,从长远来看价值股相对于成长股能够产生了更高的回报,同时小盘股的表现优于大盘股。在 Banz(1981)首次记录了美国市场中股票市值与股票收益之间的负相关关系后,价值股优于成长股的定论开始得到了广泛的研究(La Porta 1996; Barber and Lyon 1997; Daniel and Titman 1997; Lewellen 1999),其中最著名的是 Fama and French (1992、1993)以及 Lakonishok、Shleifer and Vishny (1994)的研究。价值股和小盘股的长期优秀表现可归因于众多的理论解释,但最首要的假设是公司特征可能代表特定的风险因素。例如, Fama and French(1993)、Jensen、Mercer and Johnson(1996)以及 Lewellen(1999)声称更高的回报是对承担更大风险的补偿。Fama and French(1993)表明,基于价值和规模因子的投资组合对宏观经济和金融风险因素(期限和违约利差)十分敏感。此外, Liew and Vassalou(2000)发现即使剔除被广泛使用的于商业周期相关变量后,价值(HML)和规模(SMB)因子仍包含了有关未来经济状况的重要信息。

与此同时,另一种观点是将价值股和小盘股的出色表现归因于对于股票的错

误定价。Lakonishok、Shleifer and Vishny (1994)认为较高的回报是来自于对过去业绩的不准确预测，而 La Porta (1996)将价值策略的出色表现归因于对未来收益增长的乐观预期。第三个潜在原因可能是数据窥探的问题和偏见 (Lo and MacKinlay 1990; MacKinlay 1995)。在美国股票市场之外，价值和规模溢价的持续表现同样有记录 (Fama and French 1998; Dimson, Nagel and Quigley 2003)。

然而，1990年代后期的经历使人们对价值股和小盘股超额表现的稳健性提出了质疑。在所谓的科技泡沫破灭前夕，人们对电信和科技相关股票盈利增长能力的非理性预期，推高了美国股市中成长和大盘股板块的价格，导致价值和规模因子相关的投资策略表现不佳。例如，Chan、Karceski and Lakonishok (2000)表明常规的价值和规模策略在 1990-1998 年期间发生了逆转。价值股和小盘股表现不佳说明投资风格很可能取决于当时的市场状况和周期；也就是说，宏观经济和市场条件的变化可能对不同的股票风格产生不同的影响。

通常情况下，价值股和小盘股对市场状况的变化和经济周期的演变更为敏感，因为它们没有表现出卓越的盈利能力。具体而言，因为经济状况的改善，他们在扩张时期受益最大，而在收缩时期则相反。相比之下，无论当前经济周期处于哪个阶段，成长股往往表现出较为一贯的盈利能力。这也是投资者愿意为盈利的一致性和高质量给出更高估值的主要原因。因此，理性投资者应该只在盈利增长较少（即经济衰退期间）而不是较多时（即经济扩张期）支付溢价。由此可得，风格策略的表现可能会因当前的宏观经济和市场背景而异。

美股科技泡沫的最终破灭和价值投资的反弹（即价值股和小盘股表现出色的时期以及随后表现不佳的时期）使得风格周期的存在以及与其的可预测性问题浮出水面。市场从业者开始专注于检测与市场周期有关的潜在系统模式或因素，因为这些模式或因素可以让他们在长期投资范围内提高投资业绩。通过设计有效的风格择时或轮动策略以更加明确地利用风格回报的时变性质，不仅可以改善策略表现，而且可以使得策略更加稳定，尤其是对于有着特定风格和资产配置的投资经理。

尽管能够从市场经验上承认风格周期的存在，但只有有限的实证文献直接论述了风格周期的好处和风格差异的可预测性。在这些文献中，大多数相关研究都认为投资风格周期性行为与系统性的宏观经济、金融和技术因素有关，因此在一定程度上风格周期是可以预测的。

因此，有几个原因促使我们在现在对风格周期进行详细的可预测性研究。第一，2008 年全球金融危机后，风格策略的表现更像是一条单行道：成长股表现出巨大的动力，且表现一直优于价值股，尤其是在大盘股板块。而同时，美国不同风格指数之间的相对估值也处于科技泡沫破灭前的水平。也就是说，这种情况下似乎更难利用风格轮动策略。其次，交易所交易基金(ETF)的日益普及使得风格投资变得越来越重要，因为投资者现在可以利用 ETF 更加容易地参与风格投资。第三，大多数关于风格可预测性的实证研究都集中在对于时间点的预测而不是未来风格方向变动的预测上。最后，但也是最重要的是，机器学习技术在该主题上的应用很少。与标准的计量经济学技术相比，机器学习技术的实施可以带来更卓越的预测能力，也允许人们使用更广泛的预测变量集。



本研究的主要目的是构建一系列风格转变预测模型，并运用这些模型在美国股票市场实施有效的风格轮动策略。预测结果是由标准的单变量和二元计量经济模型，以及众多机器学习技术生成的。更具体地说，单变量逻辑回归模型与多变量的逐步逻辑回归模型和几种机器学习方法，例如正则化技术（岭回归、最小绝对值收敛和选择算子 [LASSO 回归] 和弹性网络 [EN]）、判别分析方法（线性判别分析 [LDA] 和正则化判别分析 [RDA]）、贝叶斯分类器（朴素贝叶斯和贝叶斯广义线性模型 [Bayes GLM]）以及分类和回归树 (CART) 模型（装袋算法 [Bagging]、随机森林、AdaBoost 和梯度提升法 [Gradient Boosting]）均包含在本次研究中。同时，我们使用了各种统计评估指标来评估模型的预测能力，并基于模型设计了许多投资策略来评估它们的经济意义。

更具体地说，本次研究的贡献是多方面的。首先，引入了代表各种风格差异变化方向的二进制因变量，以探索是否可以使用大量预测（自）变量来预测风格的变化方向。其次，为了迎合加入更多新变量的当今研究趋势，我们在分析中考虑了一些其他研究中参考较少的预测变量。第三，我们应用了大量机器学习技术来确定这些技术中的哪一种可以提高预测性能。第四，基础分析的结果表明，特定因子的单变量逻辑回归模型和几种机器学习技术在统计学和经济学评估上展现出了有效的预测能力。

本文的其余部分结构如下：首先是对相关文献的综述，然后是对数据集的描述以及对于实证设计和发现的概述，最后是我们的结论。

## 2、文献综述

Jacobs and Levy (1996)是最早提出存在大量风格回报差异的学者之一。他们表明风格轮动提供了提高投资组合回报的可能。他们的主要假设是基于这样一个概念：即“风格属性之间的精细区分提供了可以通过被动风格索引进行风格轮动以增强回报的可能。”在实践中，他们认为准确定义的风格（即清晰准确的风格定义）可以产生更高的回报。Kao and Shumaker (1999)研究了导致周期性风格回报差异的原因，并提出了一个有效的风格划分框架。他们使用不同的罗素风格指数模拟了 1979 年 1 月至 1997 年 6 月期间的择时策略，发现基于市场的择时策略的年化收益率最高，其次是基于规模和风格的择时策略。他们继续研究在单变量框架中常用的宏观经济因素和金融市场因素之间关系，但将重点放在了非参数 CART 技术的实现，即多变量框架中的递归分区(RPA)技术。对于接下来 12 个月风格变化，该模型能够正确分类 79%的样本内时间点，以及正确分类 74%的样本外时间点。当将模型应用于三个月风格变化时，模型的准确率下降到样本内 69%和样本外 58%。

Copeland and Copeland (1999)试图利用由于市场波动变化导致股票风险溢价会随着时间变化这一性质进行研究。他们的择时策略在美国的价值-成长和大小盘指数之间进行分配。其主要理念是在预期的未来波动率上升时转换为价值指数，并在下降时转向成长指数。在规模上，他们认为在预期波动率上升时转向大盘股指数，而在预期波动率下降时则相反。他们的交易策略基于 CBOE 的隐含波动率

指数(VIX)。由此他们构建了多头价值/空头成长策略,即只要 VIX 指数超过其 75 天的移动平均线 10%、20%等至最高 80%时,就会保持 1 至 10 天不等的持有期。研究表明,当将指标设置在 20%或更高的水平上时,该策略是成功的。当实施相反的策略时,成长型投资组合的表现总是优于价值型投资组合。基于规模差异的类似策略也进行了测试并再次奏效。

Asness 等人(2000)抛弃了对于经济和市场风险相关因素的使用,而选择了基于市场估值指标的不同方法。他们在分析中引入了价值投资组合和成长投资组合之间的估值差,以及两种风格之间预期收益增长的差异。在使用 1982 年 1 月至 1999 年 10 月的数据后发现估值和收益增长利差是评估美国价值投资组合与成长投资组合相对吸引力的重要因素。对于不同的估值和收益增长,滚动 12 个月价值溢价收益的预测回归表明,由于估值的差异和预期收益的差异,未来回报预期由 35.4%变为 38.7%。

Cooper、Gulen and Vassalou(2001)引入交易策略以探索基于规模和价值排序的投资组合表现是否与基本宏观经济风险相关。该策略的投资决策来自于一个基于经济状况的预测模型,该模型反映了经济风险是否是一系列价值和规模因子收益的有效预测指标,包括 HML 和 SMB 因子。他们的结果表明,与利率和违约率相关的因子对于预测价值和规模投资组合的收益很重要。他们得出结论:规模投资组合的回报是可预测的,而价值相关的投资组合的可预测性较弱。他们的动态交易策略表现优于被动交易策略。此外,他们的交易策略受到经济状况的影响,因为其策略在经济衰退期间表现更加出色。

Lucas、van Dijk and Kloek (2002)研究了价值和规模是否随美国宏观经济条件而变化。他们在风格轮动模型中使用了期限利差和与商业周期相关的领先指标的组合。他们得出的结论是:他们的模型为不同的投资期限获得了优秀的历史超额收益;然而,他们的发现似乎与标准的风险补偿解释不一致。Wang (2005)进行了风格动量多因素分析。在这个研究中,风格动量被定义为风格轮动和动量策略的组合。在 1960 年至 2001 年期间,在前一个月买入获胜的风格并做空失败的风格策略产生了可观的利润,其年化收益率超过 16%。通过 Fama&French (1993)三因子模型进行风险调整后提升了策略的利润,但并没能解释策略收益的来源(即超额收益不是对更高风险的补偿)。他认为,一种可能的解释是风格动量策略引起了大量的多因素贝塔轮换。

Barberis and Shleifer (2003)采取了不同的方法:他们认为投资者通常只会在特定的资产类别(大盘股、小盘股、价值、成长、工业、材料)上做出投资决策以简化流程。他们的主要观点是:基于类别的投资可以比基于经济和市场基本面的投资在更大程度上促使股票的共同移动。因为,在很大程度上,投资者倾向于追逐收益或业绩。他们倾向于将资金分配到表现良好的类别和近期表现不佳的类别中。如果价值股表现出持续的优异表现,投资者将从成长股转向价值股。与普遍的观点相反,由于都具有相关的收益信息,股票往往会一起移动,他们认为这是因为同一类别内的股票对大量投资者变得更加重要。在重新分配过程中,需求压力使得特定类别的股票以相同的方式运行,但却超出了仅基于收益相关性的预期。

Nalbantov、Bauer and Sprinkhuizen-Kuyper (2006)使用一组宏观经济和技术指

请务必阅读正文之后的信息披露和重要声明

- 6 -

标来检测不通过标普风格指数构建的美国风格轮动策略是否存在盈利能力。他们没有采用标准的多因素模型框架，而是使用了支持向量回归模型来预测美国股票市场的价值和规模溢价。他们的实证研究结果表明，在 1993 年 1 月至 2002 年 12 月期间，这两种溢价都是高度可预测的。即使考虑到交易成本，这个结果也具有经济意义。价值-成长股和小盘股结合的择时策略表现出极高的信息比率。

Arshanapalli、Switzer and Panju (2007) 根据 1979 年 1 月至 2005 年 4 月期间大盘和小盘的罗素风格指数、宏观经济数据和公开可用的基本面信息，引入了多项时序模型（多变量逻辑回归）。他们基于该模型的预测在经济上产生了显著的结果：在样本外期间，他们的风格择时策略或多或少地始终优于买入并持有策略。更具体地说，通过遵循模型的建议，投资者每年可以获得至少 6.08% 的超额回报，并且比原始的风格动量策略获得超过 3% 的超额回报。即使考虑到交易成本，超额收益仍然可观。

Black、Mao and McMillan (2009) 检验了价值溢价价格指数 (VPPI) 与美国经济活动之间是否存在长期关系。他们发现 VPPI 与宏观经济指标（如工业生产、通货膨胀、货币供应量和利率）之间存在协整关系。他们的结果表明，VPPI 与工业生产和货币供应量之间存在显著的负相关关系，而与长期利率存在显著的正相关关系。他们得出的结论是，价值股对糟糕的经济状况更为敏感，而成长股则相反。

最近，Golosov and Satchell (2014) 以及 Efremidze、DiLellio and Stanley (2014) 使用 CBOE 隐含波动率指数 (VIX) 构建了两个新指标——样本熵和近似熵——以探索风格轮动的可行性。因为在之前的研究中使用了 VIX 指数的变化，风格轮动择时策略产生了好坏参半的结果。VIX 指数的水平和变化可能表明预期波动性的变化程度，但它们并未提供与潜在成分相关的任何提示。独立于波动性变化的可预测成分，熵衡量了时间序列的不确定性，并同时考虑了可能影响价值股和成长股的市场风险溢价和折现率。与基于 VIX 指数百分比变化的信号相比，基于熵的信号表现更为优异。即使设置了合理的交易成本，结果同样优秀。

此外，一些研究还探讨了美国股市以外的风格轮动的潜在好处。Levis and Liodakis (1999) 根据 1968 年至 1997 年期间英国股票市场的价值和规模分布评估了风格轮动策略的盈利能力。策略模拟表明，65%–70% 的准确率可能足以胜过几乎所有的长期小盘股策略和超过 80% 的价值股策略。他们接着研究确定了许多宏观经济和金融市场因素，这些因素能够使用逻辑回归模型以预测随后一个月的风格转变。他们得出的结论是，基于规模利差的风格轮动策略能够产生高利润，而在存在价值利差的情况下，策略具有边际利润。Bauer、Derwall and Molenaar (2004) 发现了日本股票市场风格择时盈利能力的证据，但得出的结论是，从实际的角度来看，适度的交易成本会降低结果的吸引力。最后且最重要的一点是，Bird and Casavecchia (2011) 证明了一组宏观经济和市场因素能够预测未来 12 个月期间欧洲市场价值利差的变动方向。他们基于该模型的价值-成长轮换策略产生了显著的超额回报，表明了风格分布在整个商业周期中是不同的。



### 3、数据

由于本研究的重点是构建出可以在实践中实施的有效风格轮动策略，因此大多数风格差异都是根据可交易的股票市场指数创建的，这与之前众多的实证研究一致。除了价值和规模利差这类迄今为止最广为人了解、研究和跟踪的风格差异，分析还关注了与风险相关的差异，因为风险因素在学术界和市场从业者中十分重要且常用。

具体而言，在 Fama and French(2015)的研究中，他们通过增加盈利能力和投资因素来解释三因素模型在预期收益上是不完整模型，因为原有的三因素模型没有捕捉与盈利能力和投资因素相关的平均回报的变化。盈利因子 RMW 是指盈利能力强和弱的股票投资组合之间回报之差，投资因子 CMA 是指低投资公司多元化投资组合的回报减去高投资公司多元化投资组合的回报。此外，所谓的低波动异常，即高风险股票在美国和国际股票市场中的平均表现一直低于其低风险股票的事实也一直引起人们的关注。Frazzini and Pedersen (2014) 证明高 Beta 资产组合的 Alpha 和夏普比率低于低 Beta 资产组合。更具体地说，做多低 Beta 资产和做空高 Beta 资产的贝塔 (BAB) 因子会产生正的风险调整后收益。他们得出结论，BAB 因子的回报在经济和统计显著性方面能够与所有标准资产定价因子的收益相匹敌。

本次研究中，价值利差被定义为通过持价值股指数的多头头寸和成长股指数的空头头寸计算而言。两个美国大盘股指数被用来计算潜在的价值利差。更具体地说，本次分析中的价值利差包括了标准普尔（标普）500 价值和成长指数与罗素 1000 价值和成长指数之间的回报差异。罗素风格指数相关数据的时间窗口为 1986 年 1 月至 2019 年 12 月，而标普 500 风格指数相关数据的时间窗口为 1995 年 7 月至 2019 年 12 月。同样，规模利差被定义为通过 1986 年 1 月至 2019 年 12 月期间罗素 2000 指数（小盘股）和罗素 1000 指数（大盘股）之间的回报差异计算而来。最后且最重要的是，低波动率利差由 Frazzini and Pedersen (2014) 1986 年 1 月至 2019 年 12 月期间的 BAB 因子表示。

方向指标是一个二元变量，如果某种风格的利差在  $t$  月趋势较高，则该值记为 1，如果利差较低，则该值为 0。将各个连续的利差变量的自回归项用作预测变量，以捕捉目标序列中自相关的存在。

由于风格回报可变性的主要来源是经济、信贷和金融周期中的外生和/或内生冲击，因此将一系列经济和金融变量作为可能的预测因子（自变量）是合理的。在过往的实证研究中已经表明因子的有效性在很大程度上取决于时间上的不同，因此我们需要考虑大量的预测变量。更具体地说，这组预测指标包含宏观经济和金融市场相关指标。其中一部分被政策制定者和市场从业者广泛使用，并已在现有文献中被证实对于资产回报有可预测性。同时分析中还包括了一些研究较少的指标。综上所述，预测变量主要包含与宏观经济和金融市场风险、动量和市场估值相关的风险类别，以及月频的投资者情绪因子。

宏观经济预测因素集包括期限利差、油价、美元指数、美国经济政策不确定性指数等变量，以及基于 12 个月工业生产增长标准差的宏观经济波动指标，同时



包括消费者信心指数。股票市场的表现由众多与股票相关的因子投资组合来表示。除了著名的 Fama-French 三因子投资组合、价值(HML)、规模(SMB)和市场(MKT)外,还采用了额外的因子投资组合以代表其他风险因素,例如质量(QMJ)、低波动性(BAB)和残差方差(RVAR)。此外,金融和信用风险由违约和 TED 利差、股票隐含波动率(VXO 指数)、堪萨斯城金融压力指数和芝加哥金融状况杠杆指数等表示。同时,大量的文献已证明中短期股票动量因子能够预测资产回报。因此,Fama-French 中期价格动量 (MOM) 和短期反转 (STR) 投资组合回报显然也是候选因子。然而,由于跨资产或跨市场联系的存在,我们也使用了来自各种其他资产类别(固定收益、商品和外汇)的动量因素。最后,分析中同样使用了一系列基于标普 500 指数的估值相关指标。附录中的图表 A1 提供了预测变量的完整列表及其来源。如前文所述,数据涵盖了不同的时期,具体选取哪段时间取决于数据的可用性。

## 4、实证设计和分析

本章节介绍了本次分析的实验设计。其主要目标是评估所考虑的候选建模方法在样本外的统计结果和经济绩效。首先,我们使用一组精心设计的统计评估指标来检验目标模型的预测性能,然后通过模型创建许多投资策略来评估预测结果的经济意义。

分析的起点是使用最简单的建模方法生成定向预测。首先我们为每个预测变量以及自回归分量进行单变量的逻辑回归模型。下一步将单变量模型转向多变量逻辑回归模型。在多元回归模型下,模型参数的估计非常简单,但选择出最相关的预测变量绝对不是一件容易的事,尤其是当预测变量集很大时。过往文献中已经设计了不同的模型/变量选择方式来解决该问题:如逐步回归;信息准则(例如 Akaike (AIC) (Akaike 1973) 或贝叶斯信息标准 (BIC) (Schwarz 1978));以及贝叶斯模型选择方法。分析中采用了标准的模型选择方法:基于 AIC 和 BIC 的逐步逻辑回归。

对于标准计量经济模型,总样本被分为样本内和样本外时段,以评估不同建模方法的预测性能。为了获得样本外预测,首先使用从数据集开始到样本内期结束日期的数据估计拟合模型,并生成提前一个月的预测。之后使用扩展窗口迭代地重复该过程。

与此同时,分析中还使用了各种机器学习技术。特别是,基于惩罚似然的二元逻辑回归模型,例如岭 Ridge (Hoerl and Kennard 1970)、LASSO (Tibshirani 1996) 和 EN (Zou and Hastie 2005) 的正则化技术,这些技术在回归系数中施加对于复杂性的惩罚,使得变量被自动选择并因此有助于避免过度拟合的问题。接下来,分类模型,例如 LDA 和 RDA (Friedman 1989; James 等, 2013) 和贝叶斯方法——朴素贝叶斯 (Bauer and Kohavi 1999) 和在应用中 (参见 Iworiso and Vrontos 2020、Domingos and Pazzani 1996 以及 Vrontos、Galakis and Vrontos 2021) 被证实相对准确的贝叶斯广义线性模型 GLM (Gelman 等 2008) 在本次分析中被使用。此外,本研究还包括 CART 模型 (Breiman 等 1984) 和几种结合不同树模型的集

成方法。分析的方法包括装袋算法 Bagging(Breiman 1996)、随机森林 (Breiman 2001)、AdaBoost (Freund and Schapire, 1997) 和梯度提升 (Friedman 2001, 2002)。最后, 一种非参数聚类算法, 即 K 近邻 (KNN), 被用于对所分析的风格差异以进行定向分类。

由于几种机器学习模型的性能很大程度上取决于超参数的选择 (某些技术, 例如 LDA, 因为它们没有超参数, 所以不需要调优), 我们使用 Gu、Kelly and Xiu (2020) 的方法来进行超参数调整以优化其样本外的表现。Vrontos、Galakis and Vrontos (2021) 也在建模和预测美国经济周期 (尤其是衰退) 的背景下应用这种方法设置机器学习模型中的超参数。基于这种特定的方法, 样本被划分为三个不相交的时间段 (子样本), 这些时间段保持着数据上的时间顺序, 从而考虑到数据中的序列相关结构。第一个子样本周期为训练集, 其中每个模型都根据一组特定的超参数值进行训练。第二个子样本是验证集, 我们根据此周期调整超参数的数值。这里可以通过估计替代的方式进行, 通过设置一组超参数集, 使用集合中的不同数值构建模型, 并使用训练集的数据来预测验证集的每个数据点的数据。然后, 基于验证集中的预测, 我们选择最大化目标函数的超参数数值, 在本次研究中目标函数是准确度度量, 我们 (对于所有调整的超参数值) 在迭代中不断调整超参数的最佳值以寻求最大化的准确度度量。最后, 第三个子样本是测试集, 用于检查/评估不同建模方法的样本外性能。

以标普 500 指数风格价差为例, 我们的分析数据时间窗口为 1995 年 7 月至 2019 年 12 月之间的时期 (284 个月度观测值)。我们将完整的样本分为三个不相交的时间段: 训练、验证和测试或样本外时间段。初始训练集为 1995 年 7 月至 2001 年 12 月 (78 个月度观测值), 对应的验证集为 2002 年 1 月至 2004 年 12 月 (36 个月度观测值), 测试集为 2005 年 1 月至 2019 年 12 月 (180 个月度观测值)。为了获得测试集的样本外预测, 我们采用了混合方案。该方案使用递归样本内方案, 逐渐包括训练集最近的观察值和固定的三年验证集。举例说明, 在第一次迭代中——即对于第一个样本外时期 (即 2005 年 1 月) 的预测——训练集包含 78 个月度观察值, 用于训练一组特定超参数的机器学习模型。相应的, 验证集由 36 个月度观察值组成, 用于设置不同建模方法里的超参数。基于在验证集中选择的最佳超参数值, 我们对 2005 年 1 月进行一步超前的预测。接下来, 对于第二次迭代——即构建 2005 年 2 月的预测——训练集是递归地增加一个观察值; 因此, 它包含 79 个观测值, 并且所有模型/技术都针对一组特定的超参数集进行了重新估计。相应的验证集由 36 个月度观测值的固定时间窗口组成, 并基于最优的超参数值, 进行对于 2005 年 2 月的提前一步预测。总而言之, 该方法使用训练集的扩展/递归窗口递归重复此过程以及固定验证集大小的滚动样本, 生成测试期间的样本外预测。此过程的优点是递归方案始终保留训练样本中的整个历史记录。由此看出, 该方案没有进行交叉验证。

#### 4.1、基于统计学指标的预测性能评估

在本节中, 我们按照不同的风格展示所分析建模方法的统计性能评估结果。由于多元逻辑回归模型 (基于 AIC、Schwarz BIC 和偏差指标的实时逐步回归框

请务必阅读正文之后的信息披露和重要声明

架)相关的结果并不令人满意,因此未在文中展示,但可应要求提供。基于表单的各个预测变量构建的单变量逻辑模型  $\ln(\frac{p_t}{1-p_t}) = \beta_{0,i} + \beta_{1,i}x_{i,t-1}, i = 1, \dots, N$  的定向风格方向变量样本外预测结果将被首先展示,以说明使用机器学习技术背后的潜在好处和动机。

报告的大多数性能评估指标基于混淆矩阵,该矩阵能有效评估二分类问题的预测结果。Sokolova and Lapalme (2009) Hossin and Sulaiman (2015) 以及 Tharwat (2020)等对此类问题中使用的几种表现评估措施进行了详细描述和分析。此外,诸如 ROC 曲线下面积(AUC)、误分类误差(MCE)、准确度、Kappa 统计量、敏感性和特异性、精密率、F1 分数和均衡准确率等指标也将被用于评估模型的表现。对于除 MCE 之外的所有指标,高正值均表明该模型具有卓越的预测性能。此外,对于预测的统计显著性的判断,我们使用的是基于 Pesaran and Timmermann (1992)的统计量方法。Pesaran-Timmermann (PT)统计量的正(负)值表示正确率或命中率大于(小于)错误率;因此,较高(高于临界值)的正统计值表明其具有显著的预测能力。

**图表 1、统计学表现评估: 单变量逻辑回归模型和机器学习-标普 500 利差**

Method	AUC	MCE	Accuracy	Kappa	Sensitivity	Specificity	Precision	Balanced Accuracy	Pesaran-Timmermann
Panel A: Univariate Logit Models									
HML	0.521	0.406	0.594	0.150	0.392	0.752	0.554	0.572	2.084
CMA	0.550	0.422	0.578	0.111	0.354	0.752	0.528	0.553	1.562
Lagged Value Spread	0.496	0.428	0.572	0.095	0.329	0.762	0.520	0.546	1.360
S&P 500 1m Return	0.525	0.444	0.556	0.085	0.430	0.653	0.493	0.542	1.148
3m Treasury Yield	0.510	0.428	0.572	0.060	0.165	0.891	0.542	0.528	1.090
Panel B: Machine Learning Techniques (initial in-sample period = 78, validation period = 36, out-of-sample period = 180)									
LDA	0.611	0.389	0.611	0.208	0.544	0.663	0.558	0.604	2.795
Naïve Bayes	0.555	0.372	0.628	0.215	0.405	0.802	0.615	0.604	3.041
Bayes GLM	0.601	0.433	0.567	0.115	0.481	0.634	0.507	0.557	1.549
Bagging	0.576	0.394	0.606	0.178	0.430	0.743	0.567	0.586	2.443
Ada Boosting	0.566	0.417	0.583	0.136	0.430	0.703	0.531	0.567	1.855

注: 图表 1 展示了单变量逻辑回归模型和多种机器学习模型生成的 2005 年 1 月至 2019 年 12 月样本外期基于标普 500 指数价值-成长利差的未来一个月的方向预测的相关统计评估指标。

资料来源: The Journal of Financial Data Science, 兴业证券经济与金融研究院整理

**标准普尔 500 价值指数——标准普尔 500 成长指数利差:** 实证分析的出发点是基于标普 500 价值-成长指数的利差,因为标普 500 指数是最受关注和追踪的大盘美国股市指数。由于预测变量集相当广泛,图表 1 (Panel A) 仅展示了在单变量逻辑回归模型中表现较好的因子的相关统计评估指标。

值得注意的是,表现出最高预测性能的变量是众所周知的 HML 因子的滞后值,这意味着替代性价值因子包含了与标普 500 指数相关利差的重要信息。HML 因子的 PT 统计量最高 (2.084),这意味着该因子产生了统计学上显著的预测,准确率接近 60%,但 AUC 相对较低 (52.1%)。此外,HML 是在 PT 统计量上具有显著性的唯一预测变量。另一个有趣的发现是 Fama and French (2015) 的投资相关因子 CMA 在预测变量列表中也名列前茅。这当然并不意外,因为 HML 和 CMA 因子组合具有高度的正相关性 (更多详细信息,请参阅 Fama and French 2015)。虽然它在 PT 统计量上不具有显著性,但其在 AUC 指标 (55.0%) 上排名最高,在准确性方面排名第二 (57.8%)。与前两个因素相比,利差的滞后值 (非二元变量) 表现出较低的预测能力,AUC 低于 50.0%。滞后的 1 个月标普 500 指数表



现（短期回报动能）和 3 个月国库券利率水平是其他排名靠前的因子，但只显示出相对平庸的预测能力。

继续对机器学习模型产生的预测进行统计评估，从图表 1（Panel B）可以明显看出，一些特定的模型表现出卓越的性能。更具体地说，与单变量逻辑回归模型相比，几个模型在许多指标上的评估明显更好，例如准确性、AUC 和 Kappa 统计量。例如，朴素贝叶斯模型具有最高的准确度(62.8%)、Kappa (21.5%)、均衡准确率(60.4%)和 PT 统计量(3.041)。这些值明显高于基于 HML 的单变量逻辑回归模型。除了朴素贝叶斯模型外，LDA 技术在 AUC 上排名最高（61.1%），其 PT 统计量（2.795）也表明它具有显著的预测能力。装袋算法 Bagging 和 AdaBoost 也显示出较好的结果。需要注意的是，我们测试了共 13 种机器学习模型，但仅列出了预测能力和准确性方面的前五名。

总体而言，我们的研究结果表明，机器学习技术的使用可以显著改善对标普 500 价值-成长指数利差的方向预测。

**图表 2、统计学表现评估：单变量逻辑回归模型和机器学习-罗素 1000 利差**

Method	AUC	MCE	Accuracy	Kappa	Sensitivity	Specificity	Precision	Balanced Accuracy	Pesaran-Timmermann
<b>Panel A: Univariate Logit Models</b>									
TED Spread	0.584	0.432	0.568	0.139	0.591	0.550	0.504	0.571	2.283
Chicago Fed Financial Conditions Leverage Index	0.567	0.417	0.583	0.103	0.278	0.819	0.542	0.549	1.877
S&P 500 Dividend Yield	0.534	0.439	0.561	0.112	0.522	0.591	0.496	0.556	1.816
Macro Volatility	0.509	0.417	0.583	0.076	0.157	0.913	0.581	0.535	1.734
Gold Price	0.561	0.420	0.580	0.072	0.174	0.893	0.556	0.533	1.562
<b>Panel B: Machine Learning Techniques (initial in-sample period = 108, validation period = 36, out-of-sample period = 264)</b>									
LDA	0.528	0.451	0.549	0.068	0.409	0.658	0.480	0.533	1.107
RDA	0.594	0.417	0.583	0.148	0.496	0.651	0.523	0.573	2.400
Naive Bayes	0.563	0.424	0.576	0.139	0.522	0.617	0.513	0.570	2.257
Bagging	0.582	0.436	0.564	0.113	0.496	0.617	0.500	0.557	1.840
KNN	0.560	0.417	0.583	0.127	0.391	0.732	0.529	0.561	2.118

注：图表 2 展示了单变量逻辑回归模型和多种机器学习模型生成的 1998 年 1 月至 2019 年 12 月样本外基于罗素 1000 指数价值-成长利差的未来一个月方向预测的相关统计评估指标。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

**罗素 1000 价值指数—罗素 1000 成长指数利差：**另一种被广泛追踪但更多样化的美国大盘股指数是罗素 1000 指数。出于对于一致性和稳健性的测试，我们也需要分析基于该指数的利差预测。其结论与标普 500 指数利差的结论没有太大区别。

有趣的是，在单变量逻辑回归模型上，表现较好的因子与基于标普 500 利差得出的结果大不相同。其表现最佳的模型是由流动性、杠杆、宏观经济风险和风险规避因素构成。排名靠前的单变量模型的表现似乎优于基于标普 500 指数利差的模型。基于 TED 利差的模型在众多指标上表现出最高的预测准确性，以及具有统计显著性的预测能力，其次是芝加哥金融状况杠杆指数（图表 2，Panel A）。

总体而言，单变量逻辑回归模型的预测性能仍然不如性能最佳的机器学习模型。RDA 模型表现出最高的准确度，AUC 为 59.4%，MCE 为 41.7%。与标普 500 指数利差中的情况一样，朴素贝叶斯、装袋算法 Bagging 与 KNN 模型同样展示了卓越的预测性能。他们的 PT 统计值均高于 1.84，且准确度介于 56.4%和 58.3%之间。

**罗素 2000 指数——罗素 1000 指数利差：**在调查了美国大盘股价值-成长利差



的可预测性之后，现在我们将注意力集中在规模溢价或规模周期的可预测性上。规模是第二种被大量研究和跟踪的风格轮动策略。在图表 3（Panel A）展示了单变量逻辑回归模型的性能。似乎在这种风格的研究下，风格的预测性更高。因为所有排名靠前的模型都具有显著的 PT 统计数据（范围在 1.712 和 2.524 之间）。有趣的是，在这种情况下大盘股收益动量（标普 500 指数 12 个月和标普 500 指数 6 个月收益动量因子）和杠杆相关因子（QMJ 因子组合及其利差）表现最为优秀。

**图表 3、统计学表现评估：单变量逻辑回归模型和机器学习-规模利差**

Method	AUC	MCE	Accuracy	Kappa	Sensitivity	Specificity	Precision	Balanced Accuracy	Pesaran-Timmermann
<b>Panel A: Univariate Logit Models</b>									
S&P 500 12m Momentum	0.560	0.428	0.572	0.148	0.425	0.723	0.613	0.574	2.524
QMJ	0.544	0.436	0.564	0.131	0.493	0.638	0.584	0.565	2.151
Change in Consumer Sentiment	0.499	0.451	0.549	0.104	0.366	0.738	0.590	0.552	1.822
S&P 500 6m Momentum	0.553	0.451	0.549	0.102	0.418	0.685	0.577	0.551	1.727
Credit Spread	0.549	0.447	0.553	0.105	0.582	0.523	0.557	0.553	1.712
<b>Panel B: Machine Learning Techniques (initial in-sample period = 108, validation period = 36, out-of-sample period = 264)</b>									
RDA	0.539	0.462	0.538	0.076	0.537	0.538	0.545	0.538	1.231
Naïve Bayes	0.576	0.409	0.591	0.184	0.515	0.669	0.616	0.592	3.027
Bayes GLM	0.467	0.466	0.534	0.070	0.485	0.585	0.546	0.535	1.138
Gradient Boosting	0.564	0.466	0.534	0.068	0.552	0.515	0.540	0.534	1.099
KNN	0.512	0.485	0.515	0.035	0.373	0.662	0.532	0.517	0.588

注：图表 3 展示了单变量逻辑回归模型和多种机器学习模型生成的 1998 年 1 月至 2019 年 12 月样本外基于规模利润的未来一个月方向预测的相关统计评估指标。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

机器学习相对于单变量逻辑回归模型的优势还体现在单个机器学习模型表现几乎都具有更高的预测准确性这一事实上。更具体地说，朴素贝叶斯模型在几个指标上排名第一。该模型不仅拥有最高的 PT 统计量 (3.027)，而且拥有最高的准确度(59.1%)、AUC (57.6%) 和 Kappa (18.4%) 指标。相比之下，其余的机器学习模型没有表现出显著的预测能力：他们的 PT 统计数据在统计上不显著。

**BAB 利差：**最近，所谓的低波动异常——即高风险股票的平均表现一直低于美国和国际股票市场的低风险股票这一事实——引起了人们的关注。Frazzini and Pedersen (2014) 证明高 Beta 资产组合的 Alpha 和夏普比率低于低 Beta 资产组合。更具体地说，BAB 因子是多头低 Beta 资产和空头高 Beta 资产而产生的正的长期风险调整后收益。因此，我们在分析中引入 BAB 因子，以探索低波动率与高波动率利差的预测性。

图表 4、统计学表现评估：单变量逻辑回归模型和机器学习- BAB 利差

Method	AUC	MCE	Accuracy	Kappa	Sensitivity	Specificity	Precision	Balanced Accuracy	Pesaran-Timmermann
<b>Panel A: Univariate Logit Models</b>									
Chicago Fed Financial Conditions	0.615	0.326	0.674	0.161	0.958	0.177	0.671	0.568	3.682
S&P 500 3m Momentum	0.609	0.330	0.670	0.176	0.923	0.229	0.677	0.576	3.498
Chicago Fed Financial Conditions Leverage Index	0.605	0.333	0.667	0.173	0.911	0.240	0.677	0.575	3.347
S&P 500 6m Momentum	0.595	0.341	0.659	0.154	0.905	0.229	0.673	0.567	2.982
S&P 500 1m Momentum	0.597	0.341	0.659	0.122	0.946	0.156	0.663	0.551	2.792
VXO Index	0.639	0.348	0.652	0.103	0.940	0.146	0.658	0.543	2.347
<b>Panel B: Machine Learning Techniques (initial in-sample period = 108, validation period = 36, out-of-sample period = 264)</b>									
LASSO	0.680	0.318	0.682	0.256	0.851	0.385	0.708	0.618	4.363
EN	0.681	0.311	0.689	0.274	0.857	0.396	0.713	0.626	4.664
Naive Bayes	0.668	0.314	0.686	0.304	0.786	0.510	0.737	0.648	4.954
Bayes GLM	0.674	0.322	0.678	0.270	0.810	0.448	0.720	0.629	4.462
Ridge	0.656	0.307	0.693	0.284	0.857	0.406	0.716	0.632	4.830

注：图表 4 展示了单变量逻辑回归模型和多种机器学习模型生成的 1998 年 1 月至 2019 年 12 月样本外基于 BAB 利差的未来一个月方向预测的相关统计评估指标。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

图表 4（Panel A）展示了单变量逻辑模型的结果，很明显，单变量预测模型展示出很强的预测性。最突出的预测变量因子主要包括了与流动性和收益动量相关的因子。有趣的是，在排名靠前的三个预测变量中，有两个是芝加哥联邦储备银行金融状况指数的变式，而其余的则与标普 500 指数中短期收益动量有关。所有预测变量都显示出显著的定向预测能力：其相应的 PT 统计值均高于 2.347，准确度均超过 65.2%。

然而，最重要的发现是表现排名靠前的机器学习模型达到了接近 70.0% 的准确度水平和高均衡准确率（图 4，Panel B）。这些统计指标远高于与价值和规模利差相关的统计指标。其主要原因可能是 BAB 利差不能实时交易，因此不太容易受到噪音的影响。朴素贝叶斯模型则再一次是表现最好的模型之一，而惩罚似然模型的排名第一次明显上升。特别是 EN 模型显示出最高的 AUC（68.1%）和准确度（68.9%）。

## 4.2、基于实时交易策略的经济表现评估

为了评估每个模型预测结果的经济意义，我们构建了一系列基于相关风格、相关指数以及各自风格利差的投资策略。

最简单的出发点是专注于一种最单纯的策略（例如被动跟踪特定风格指数或特定风格利差）。例如，价值投资者可以选择持续做多标普 500 价值指数，或者构建一个杠杆更高的策略，如做多标普 500 价值指数并做空相应的成长指数（即跟踪特定的利差）。同样，成长型投资者可以采取相反的立场。这种单纯的策略可以作为评估主动投资策略的基准。

第一个策略（策略 1）是当预测模型表明价值股预计会上涨时做多各自的价值指数（例如，标普 500 价值指数），同时当成长股预计会上涨时做多成长指数（例如，标普 500 成长指数）。这种策略只需要多头头寸。第二种策略（策略 2）的杠杆更高；当价值股预期上升时，它做多价值指数并做空成长指数，而当价值股预期下降时，它采取相反的立场。这两种策略都可以在规模利差上进行复制和构建。根据策略 2 在规模利差上重新构建以构建策略 3。所有与价值和规模相关的策略都是完全可复制的，并可以通过 ETF 实施。如今，投资者可以使用许多与风格相关的 ETF。计算中不考虑交易成本。本次研究使用了多种绩效风险评估指

请务必阅读正文之后的信息披露和重要声明

标以评估策略，例如年化收益率和风险、夏普和 Sortino 比率、下行风险以及 Alpha 和 Beta 系数。

图表 5、经济学表现评估：单变量逻辑回归模型和机器学习-标普 500 利差

Method/Model	Strategy	Annual. Return	Annual. Risk	Sharpe Ratio	Sortino Ratio	Downside Risk	Alpha (S&P 500 Index)	Beta (S&P 500 Index)
<b>Panel A: Benchmark Strategies</b>								
Benchmark Strategies	S&P 500 Value Index	4.91	15.12	0.16	0.18	13.29	-0.17	1.05
	S&P 500 Growth Index	8.37	13.65	0.43	0.52	11.31	0.15	0.95
	Value Spread	-3.21	6.55	-0.87	-1.15	4.94	-0.33	0.11
	Growth Spread	3.76	6.66	0.19	0.32	3.99	0.37	-0.12
<b>Panel B: Univariate Logit Models</b>								
HML	Strategy 1	8.98	14.07	0.46	0.58	11.24	0.18	0.98
	Strategy 2	4.48	6.38	0.31	0.49	4.09	0.39	-0.04
	Strategy 3	4.45	6.50	0.30	0.47	4.22	0.39	-0.05
CMA	Strategy 1	8.26	13.98	0.41	0.50	11.58	0.13	0.97
	Strategy 2	3.10	6.45	0.10	0.15	4.22	0.29	-0.06
	Strategy 3	3.08	6.56	0.09	0.14	4.35	0.29	-0.06
Lagged Value Spread	Strategy 1	8.56	14.04	0.43	0.53	11.57	0.15	0.98
	Strategy 2	3.66	6.42	0.18	0.29	4.10	0.33	-0.05
	Strategy 3	3.60	6.54	0.17	0.27	4.23	0.32	-0.05
<b>Panel C: Machine Learning Techniques</b>								
Naive Bayes	Strategy 1	8.98	13.73	0.47	0.58	11.21	0.20	0.96
	Strategy 2	4.48	6.38	0.31	0.50	3.96	0.42	-0.09
	Strategy 3	4.53	6.49	0.32	0.50	4.09	0.42	-0.10
Bagging	Strategy 1	8.96	13.83	0.47	0.58	11.22	0.19	0.96
	Strategy 2	4.43	6.39	0.31	0.52	3.77	0.40	-0.08
	Strategy 3	4.47	6.49	0.31	0.51	3.89	0.41	-0.08
LDA	Strategy 1	8.77	13.89	0.45	0.56	11.22	0.18	0.97
	Strategy 2	4.08	6.41	0.25	0.36	4.44	0.37	-0.07
	Strategy 3	4.16	6.51	0.26	0.37	4.51	0.38	-0.08
Ada Boosting	Strategy 1	8.47	13.91	0.43	0.53	11.29	0.15	0.97
	Strategy 2	3.51	6.43	0.16	0.26	3.97	0.33	-0.07
	Strategy 3	3.53	6.54	0.16	0.26	4.06	0.33	-0.07
Bayes GLM	Strategy 1	8.35	13.68	0.43	0.53	11.03	0.15	0.95
	Strategy 2	3.27	6.44	0.12	0.19	4.12	0.32	-0.10
	Strategy 3	3.38	6.55	0.14	0.22	4.18	0.34	-0.11

注：图表 5 展示标普 500 价值-成长指数的基础投资策略及其相应利差相关策略的几个绩效评估指标。这些策略基于由单变量逻辑回归模型和其他机器学习生成的基于标普 50 指数的价值-成长利差的未来一个月方向预测，时间窗口为样本外 2005 年 1 月至 2019 年 12 月。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

**标普 500 价值指数——标普 500 成长指数利差：**图表 5 (Panel A) 展示了几个被动的跟踪风格指数和被动利差策略的绩效评估指标，包括 Alpha 和 Beta 的估计系数与参考基准（核心标普 500 指数收益）的对比。毫不奇怪，在 2005 年至 2019 年期间，价值股在非风险和风险调整后的表现均明显低于成长股。更具体地说，对标普 500 价值指数的投资每年比标普 500 成长指数中的类似策略落后 3% 以上。成长策略的夏普比率（0.43）几乎是价值策略（0.16）的三倍；Sortino 比率也是如此。价值策略较高的风险情况还体现在较高的下行风险（13.29% 对 11.31%）和相关的 Beta 系数（1.05 对 0.95）上。

图表 5(Panel B)记录了统计评估指标中排名最高的单变量逻辑模型的经济表现评估结果。与被动增长策略相比，基于 HML 预测模型构建的主动策略获得的风险调整后收益较高，而基于滞后价值利差预测获得的风险调整后收益也几乎相当。

机器学习模型的经济评估在 Panel C 中展示，主要结论是：只有一部分的模型表现出优越的性能。相对于被动增长策略和表现最好的单变量逻辑回归模型，基于装袋算法 Bagging 和朴素贝叶斯预测的主动投资策略有着最高的夏普和 Sortino

请务必阅读正文之后的信息披露和重要声明

- 15 -

比率。

图表 6、经济学表现评估：单变量逻辑回归模型和机器学习-罗素 1000 利差

Method/Model	Strategy	Annual. Return	Annual. Risk	Sharpe Ratio	Sortino Ratio	Downside Risk	Alpha (Russell 1000 Index)	Beta (Russell 1000 Index)
<b>Panel A: Benchmark Strategies</b>								
Benchmark Strategies	Russell 1000 Value Index	4.82	15.05	0.19	0.23	12.49	-0.04	0.93
	Russell 1000 Growth Index	6.30	17.24	0.25	0.31	14.04	0.00	1.08
	Value Spread	-0.44	10.95	-0.21	-0.33	7.04	0.04	-0.17
	Growth Spread	1.62	10.73	-0.03	-0.03	8.79	0.06	0.16
<b>Panel B: Univariate Logit Models</b>								
TED Spread	Strategy 1	7.62	16.66	0.34	0.41	13.80	0.12	1.04
	Strategy 2	3.97	10.49	0.20	0.24	8.56	0.29	0.08
	Strategy 3	3.41	10.91	0.14	0.15	9.73	0.24	0.08
Chicago Fed Financial Conditions Leverage Index	Strategy 1	7.81	15.91	0.37	0.46	12.80	0.16	0.99
	Strategy 2	4.33	10.48	0.23	0.32	7.49	0.36	-0.02
	Strategy 3	4.20	10.89	0.21	0.29	8.03	0.36	-0.03
S&P 500 Dividend Yield	Strategy 1	7.30	15.33	0.35	0.45	11.93	0.14	0.96
	Strategy 2	3.35	10.51	0.14	0.21	6.87	0.32	-0.10
	Strategy 3	3.63	10.90	0.16	0.25	6.98	0.35	-0.11
<b>Panel C: Machine Learning Techniques</b>								
RDA	Strategy 1	7.88	15.74	0.38	0.47	12.78	0.17	0.98
	Strategy 2	4.46	10.47	0.24	0.34	7.61	0.39	-0.05
	Strategy 3	4.80	10.87	0.27	0.39	7.46	0.42	-0.07
KNN	Strategy 1	8.10	16.64	0.37	0.45	13.74	0.16	1.04
	Strategy 2	4.89	10.46	0.28	0.35	8.55	0.36	0.08
	Strategy 3	4.32	10.88	0.22	0.25	9.74	0.31	0.08
LDA	Strategy 1	7.81	16.17	0.37	0.44	13.28	0.15	1.01
	Strategy 2	4.34	10.48	0.23	0.33	7.42	0.35	0.01
	Strategy 3	4.16	10.89	0.21	0.27	8.24	0.34	0.00
Naïve Bayes	Strategy 1	7.58	15.84	0.36	0.44	12.74	0.15	0.98
	Strategy 2	3.88	10.49	0.19	0.25	7.73	0.34	-0.04
	Strategy 3	4.22	10.89	0.21	0.30	7.74	0.37	-0.06
Bagging	Strategy 1	6.64	15.54	0.30	0.37	12.93	0.09	0.96
	Strategy 2	2.07	10.53	0.02	0.02	9.54	0.21	-0.09
	Strategy 3	2.29	10.93	0.03	0.04	9.99	0.23	-0.09

注：图表 6 展示了罗素 1000 价值-成长的基础投资策略及其相应利差相关策略的几个绩效评估指标。这些策略基于由单变量逻辑回归模型和其他机器学习生成的基于罗素 1000 价值-成长利差的未来一个月方向预测，时间窗口为样本外 1998 年 1 月至 2019 年 12 月。


资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

**罗素 1000 价值指数—罗素 1000 成长指数利差：**另一种（罗素）价值-成长指数利差的结果如图表 6 所示。正如预期的那样，被动成长策略优于被动价值策略，这与标普 500 指数的情况一样；然而，其优异的幅度要低得多，分别为 1.48% 和 3.46%（年化收益率）。此外，相对于相应的标普 500 风格指数（Panel A），罗素 1000 价值指数和成长指数都具有更高的年化风险。

基于单变量逻辑回归模型的主动策略在风险调整后表现上明显优于被动成长策略。它们表现出更高的夏普和 Sortino 比率，以及更高的 Alpha（Panel B）。唯一略微优于表现最佳的单变量逻辑模型的机器学习相关主动策略是基于 RDA 和 KNN 的策略（Panel C）。



图表 7、部分风格策略表现



注：Panel A 展示了基础的被动风格策略的净值曲线，以及基于罗素 1000 价值-成长指数利差的 RDA 模型生成的主动策略的净值曲线。Panel B 展示了基础的被动风格策略的净值曲线，以及基于罗素 1000 风格利差相关的 RDA 模型生成的主动策略的净值曲线。Panel C 展示了基础的被动风格策略的净值曲线，以及基于罗素 2000 和 1000 指数相关的朴素贝叶斯模型生成的主动策略的净值曲线。Panel D 显示了被动风格策略的净值曲线，以及基于从与规模利价相关的朴素贝叶斯模型生成的预测的主动策略的净值曲线。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

图表 7 的 Panel A 和 B 展示了基于 RDA 模型生成的买入和卖出信号的策略 1 和策略 2 的净值曲线。很明显，基于 RDA 模型的策略 1 在长期投资情况下表现明显优于被动策略。

**罗素 2000 指数——罗素 1000 指数利差：**由于规模利差是基于罗素 2000 和罗素 1000 指数之间的回报差异，因此小盘股和大盘股的被动策略代表对相应指数的投资。需要提醒的是，大量实证研究指出价值股和小盘股在长期投资范围内的表现优异。这一发现在 1998-2019 年期间没有得到证实。因此，与价值股的表现不佳相一致，小盘股的投资策略产生了较低的风险调整后收益也就不足为奇了（图表 8，Panel A）。具体而言，被动的大盘股策略具有较高的夏普比率和 Sortino 比率（分别为 0.26 和 0.32），以及较低的下行风险（12.31%）。

图表 8、经济学表现评估：单变量逻辑回归模型和机器学习-规模利差

Method/Model	Strategy	Annual Return	Annual Risk	Sharpe Ratio	Sortino Ratio	Downside Risk	Alpha (Russell 3000 Index)	Beta (Russell 3000 Index)
<b>Panel A: Benchmark Strategies</b>								
Benchmark Strategies	Small Passive	6.24	19.94	0.22	0.28	15.22	-0.04	1.15
	Large Passive	5.81	15.23	0.26	0.32	12.31	0.00	0.99
	Small Spread	0.08	10.30	-0.18	-0.26	7.05	-0.07	0.17
	Large Spread	0.98	10.38	-0.09	-0.15	6.37	0.16	-0.17
<b>Panel B: Univariate Logit Models</b>								
S&P 500 Index 12m Momentum	Strategy 1	8.17	17.58	0.36	0.44	14.38	0.15	1.08
	Strategy 2	4.12	10.22	0.22	0.31	7.13	0.32	0.03
	Strategy 3	4.03	10.23	0.21	0.29	7.28	0.32	0.02
QMJ	Strategy 1	8.10	16.70	0.37	0.50	12.39	0.18	0.99
	Strategy 2	3.97	10.22	0.20	0.29	7.04	0.40	-0.15
	Strategy 3	4.34	10.22	0.24	0.36	6.76	0.43	-0.16
Change in Consumer Sentiment	Strategy 1	7.69	17.14	0.34	0.41	14.02	0.11	1.07
	Strategy 2	3.19	10.24	0.13	0.18	6.97	0.26	0.01
	Strategy 3	3.12	10.26	0.12	0.17	7.09	0.25	0.01
<b>Panel C: Machine Learning Techniques</b>								
Naïve Bayes	Strategy 1	8.95	17.41	0.40	0.53	13.36	0.23	1.03
	Strategy 2	5.62	10.16	0.37	0.51	7.29	0.50	-0.08
	Strategy 3	5.83	10.16	0.39	0.55	7.12	0.52	-0.09
RDA	Strategy 1	6.89	17.95	0.28	0.34	14.52	0.06	1.06
	Strategy 2	1.65	10.27	-0.03	-0.04	7.28	0.15	-0.02
	Strategy 3	1.72	10.28	-0.02	-0.03	7.17	0.15	-0.02
Bayes GLM	Strategy 1	6.58	16.82	0.28	0.35	13.48	0.05	1.02
	Strategy 2	1.06	10.28	-0.08	-0.11	7.94	0.13	-0.09
	Strategy 3	1.27	10.29	-0.06	-0.08	7.76	0.15	-0.10
KNN	Strategy 1	6.33	17.64	0.25	0.31	14.34	0.01	1.05
	Strategy 2	0.59	10.28	-0.13	-0.16	8.14	0.06	-0.03
	Strategy 3	0.66	10.29	-0.12	-0.16	8.09	0.07	-0.03
Gradient Boosting	Strategy 1	4.72	17.06	0.16	0.20	13.86	-0.10	1.03
	Strategy 2	-2.45	10.26	-0.42	-0.55	7.90	-0.17	-0.07
	Strategy 3	-2.29	10.27	-0.41	-0.54	7.80	-0.16	-0.07

注：图表 8 展示了规模价差的基础投资策略及其相应价差相关策略的几个绩效评估指标。这些策略基于由单变量逻辑回归模型和其他机器学习生成的基于规模价差的未来一个月方向预测，时间窗口为样本外 1998 年 1 月至 2019 年 12 月。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

图表 8（Panel B）展示了相应因子的单变量逻辑模型生成的策略的经济评估指标。更具体地说，其展示了基于统计评估排名靠前的三个模型（即标普 500 指数中期收益动量、QMJ 因子和消费者情绪变化）的表现。表现最好的主动策略是基于 QMJ 因子模型的策略，与大盘股被动策略相比，策略 1 的夏普比率(0.37)和 Sortino 比率(0.50)要高得多。

然而，机器学习模型的性能并不那么稳健。与被动模型和单因素模型相比，只有朴素贝叶斯模型预测的主动策略才能产生更高的风险调整后收益。这也反映在与被动策略相比的情况下，基于该模型的主动策略的长期表现明显优于被动策略（图表 7，Panel C 和 D）。

**BAB 利差：**分析结果证实了低波动性策略的显著表现。做多低 Beta 股票和做空高 Beta 股票的被动投资有着近 7.33%的年化收益率和 0.45 的 Sortino 比率（图表 9，Panel A）。

前两个单变量模型（即芝加哥联储国家金融状况杠杆指数和标普 500 指数三个月收益动量）的风险调整后表现优于被动低波动率策略，其夏普和 Sortino 比率超过 0.60（图表 9，Panel A）。同时，其他机器学习模型的预测能力非常出色。根据朴素贝叶斯、EN、LASSO、岭回归和贝叶斯广义线性模型 GLM 预测的主动策略产生了卓越的风险调整后表现，其夏普和 Sortino 比率介于 0.83 和 1.29 之间（图表 9，Panel C）。

请务必阅读正文之后的信息披露和重要声明

图表 9、经济学表现评估：单变量逻辑回归模型和机器学习-BAB 利差

Method/Model	Strategy	Annual Return	Annual Risk	Sharpe Ratio	Sortino Ratio	Downside Risk	Alpha (Russell 3000 Index)	Beta (Russell 3000 Index)
<b>Panel A: Benchmark Strategies</b>								
Benchmark Strategies	Small Passive	6.24	19.94	0.22	0.28	15.22	-0.04	1.15
	Large Passive	5.81	15.23	0.26	0.32	12.31	0.00	0.99
	Small Spread	0.08	10.30	-0.18	-0.26	7.05	-0.07	0.17
	Large Spread	0.98	10.38	-0.09	-0.15	6.37	0.16	-0.17
<b>Panel B: Univariate Logit Models</b>								
S&P 500 Index 12m Momentum	Strategy 1	8.17	17.58	0.36	0.44	14.38	0.15	1.08
	Strategy 2	4.12	10.22	0.22	0.31	7.13	0.32	0.03
	Strategy 3	4.03	10.23	0.21	0.29	7.28	0.32	0.02
QMJ	Strategy 1	8.10	16.70	0.37	0.50	12.39	0.18	0.99
	Strategy 2	3.97	10.22	0.20	0.29	7.04	0.40	-0.15
	Strategy 3	4.34	10.22	0.24	0.36	6.76	0.43	-0.16
Change in Consumer Sentiment	Strategy 1	7.69	17.14	0.34	0.41	14.02	0.11	1.07
	Strategy 2	3.19	10.24	0.13	0.18	6.97	0.26	0.01
	Strategy 3	3.12	10.26	0.12	0.17	7.09	0.25	0.01
<b>Panel C: Machine Learning Techniques</b>								
Naive Bayes	Strategy 1	8.95	17.41	0.40	0.53	13.36	0.23	1.03
	Strategy 2	5.62	10.16	0.37	0.51	7.29	0.50	-0.08
	Strategy 3	5.83	10.16	0.39	0.55	7.12	0.52	-0.09
RDA	Strategy 1	6.89	17.95	0.28	0.34	14.52	0.06	1.06
	Strategy 2	1.65	10.27	-0.03	-0.04	7.28	0.15	-0.02
	Strategy 3	1.72	10.28	-0.02	-0.03	7.17	0.15	-0.02
Bayes GLM	Strategy 1	6.58	16.82	0.28	0.35	13.48	0.05	1.02
	Strategy 2	1.06	10.28	-0.08	-0.11	7.94	0.13	-0.09
	Strategy 3	1.27	10.29	-0.06	-0.08	7.76	0.15	-0.10
KNN	Strategy 1	6.33	17.64	0.25	0.31	14.34	0.01	1.05
	Strategy 2	0.59	10.28	-0.13	-0.16	8.14	0.06	-0.03
	Strategy 3	0.66	10.29	-0.12	-0.16	8.09	0.07	-0.03
Gradient Boosting	Strategy 1	4.72	17.06	0.16	0.20	13.86	-0.10	1.03
	Strategy 2	-2.45	10.26	-0.42	-0.55	7.90	-0.17	-0.07
	Strategy 3	-2.29	10.27	-0.41	-0.54	7.80	-0.16	-0.07

注：图表 9 展示了 BAB 价差的基础投资策略及其相应价差相关策略的几个绩效评估指标。这些策略基于由单变量逻辑回归模型和其他机器学习生成的基于 BAB 价差的未来一个月方向预测，时间窗口为样本外 1998 年 1 月至 2019 年 12 月。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

## 5、总结

鉴于通过被动或指数跟踪策略管理的资产数目显著增加以及与指数挂钩的金融产品数目的相应增加，投资者能够更加简单地运用它们。因此，本研究的主要目的是重新审视风格轮动策略。此外，有一种看法认为，最近利用风格轮动策略可能更加困难。因此，更具体地说，本次研究分析的重点是探索创新性建模方法的应用是否能提升相应风格的可预测性。为此，不同的建模方法（单变量逻辑回归模型、多变量逻辑回归模型和大量机器学习模型）被应用于对多种风格利差（价值、规模、低波动性）并进行风格上的定向预测。其样本外的预测能力和准确性已经在统计和经济环境中进行了评估。我们使用多种统计评估指标对模型进行比较，同时构建相应的可交易投资策略评估其经济表现。

本次研究主要结论是，基于特定因子的单变量逻辑回归模型，以及某些机器学习模型能够提高样本外预测的准确性，而多变量逻辑回归模型总体上表现较差。具体而言，不同模型的预测能力存在很大的差异；然而，一些机器学习模型不仅表现出良好的性能（朴素贝叶斯、装袋算法 Bagging、贝叶斯广义线性模型 GLM、判别分析模型和 K 邻近），而且与表现较好的单变量逻辑回归模型相比，还具有

请务必阅读正文之后的信息披露和重要声明

- 19 -

更高的准确性。该分析引用了一套精心挑选的预测变量，包括多达 46 个被市场从业者广泛遵循的宏观经济和金融市场相关指标，其中一部分甚至尚未在现有文献中用于风格轮动的预测上。

本次研究建议：研究中使用的预测框架可以帮助资产配置者加强其决策过程并由此构建出新的 Alpha 策略。

**风险提示：**文献中的结果均由相应作者通过历史数据统计、建模和测算完成，在政策、市场环境发生变化时模型存在失效的风险。



## 附录

图表 A1、预测变量集

Predictive Variable	Unit	Transformation	Source
1 10-year Treasury yield	(%)	—	FRED Database
2 3-month T-bill rate	(%)	—	FRED Database
3 Term spread—10-year Treasury yield – 3-month T-bill rate	(%)	—	FRED Database
4 TED spread	(%)	—	FRED Database
5 Credit spread—Moody's BAA yield over 10-year Treasury yield	(%)	—	FRED Database
6 Gold 1-month return in US dollars	(%)	Month-on-month % change	FRED Database
7 Economic Policy Uncertainty Index (ECU)	level	—	Economic Policy Uncertainty
8 Macroeconomic volatility (MacVol)—Industrial production growth	(%)	Annualized 12-month rolling SDEV	FRED Database
9 VXO Index level—Monthly average	(%)	—	CBOE
10 Industrial production growth	(%)	Year-on-year % change	FRED Database
11 ISM Manufacturing Index new orders	(%)	Monthly difference	ISM
12 Chicago Fed National Financial Conditions Index	Z-score	Normalized	FRED Database
13 Chicago Fed National Financial Conditions Leverage Subindex	Z-score	Normalized	FRED Database
14 Chicago Fed National Activity Index	Z-score	Normalized	FRED Database
15 Core Producer Price Index	(%)	Year-on-year % change	FRED Database
16 Dollar Index	(%)	Month-on-month % change	FRED Database
17 S&P 500 Index 1-month return	(%)	Month-on-month % change	FRED Database
Predictive Variable	Unit	Transformation	Source
18 S&P 500 Index 3-month return	(%)	3-month % change	FRED Database
19 S&P 500 Index 6-month return	(%)	6-month % change	FRED Database
20 S&P 500 Index 12-month return	(%)	12-month % change	FRED Database
21 S&P 500 Index 12-month minus 1-month return	(%)	11-month % change	FRED Database
22 University of Michigan Consumer Sentiment index	—	Change from a year ago	FRED Database
23 Real money supply M2	(%)	Year-on-year % change	FRED Database
24 S&P 500 Index—Dividend yield	(%)	—	S&P
25 S&P 500 Index—Price-to-earnings ratio	(x)	—	S&P
26 S&P 500 Index earnings yield—Treasury yield difference	(%)	—	FRED Database/S&P
27 SMB factor monthly portfolio Returns—Small minus big—Size factor	(%)	—	Fama-French
28 HML factor monthly portfolio returns—High minus low—Value factor	(%)	—	Fama-French
29 RMW factor portfolio returns—Profitability factor	(%)	—	Fama-French
30 CMA factor portfolio returns—Investment factor	(%)	—	Fama-French
31 MOM factor portfolio returns—Medium price momentum factor	(%)	—	Fama-French
32 STREV factor portfolio returns—Short-term reversal factor	(%)	—	Fama-French
33 RVAR factor portfolio returns—Residual variance factor	(%)	—	AQR
34 BAB factor portfolio returns—Betting against beta factor	(%)	—	AQR
35 HMLD factor portfolio returns—High minus low devil factor	(%)	—	AQR
36 QMJ factor portfolio returns—Quality minus junk factor	(%)	—	AQR
37 TSMOM factor portfolio returns—Diversified asset medium-term price momentum	(%)	—	AQR
38 MOM CM factor portfolio returns—Commodities medium-term price momentum	(%)	—	AQR
39 MOM EQ factor portfolio returns—Equity market medium-term price momentum	(%)	—	AQR
40 MOM FI factor portfolio returns—Fixed income market medium-term price momentum	(%)	—	AQR
41 MOM FX factor portfolio returns—Foreign exchange market medium-term price momentum	(%)	—	AQR
42 Lagged continuous style spread—1-month	(%)	—	—
Extra variables used for the S&P 500 Index value spread only			
1 S&P 500 value—Growth index earnings yield difference	(%)	—	S&P
2 S&P 500 value—Growth index dividend yield difference	(%)	—	S&P
3 S&P 500 Index forward price earnings ratio	(x)	—	S&P
4 Kansas City Financial Stress Index	Z-score	Normalized	FRED Database

注：图表 A1 展示了在分析中使用到的预测变量（因子）的详细信息。

资料来源：The Journal of Financial Data Science，兴业证券经济与金融研究院整理

## 参考文献

- 【1】Akaike, H. "Information Theory and an Extension of the Maximum Likelihood Principle." In Information Theory: Proceedings of the 2nd International Symposium, edited by B. N. Petrov and F. Csaki, pp. 267–281, Budapest: Akademia Kiado, 1973.
- 【2】Arshanapalli, B. G., L. N. Switzer, and K. Panju. 2007. "Equity-Style Timing: A Multi-Style Rotation Model for the Russell Large-Cap and Small-Cap Growth and Value Style Indexes." The Journal of Asset Management 8 (1): 9–23.
- 【3】Asness, C. S., J. A. Friedman, R. J. Krail, and J. M. Liew. 2000. "Style Timing: Value versus Growth." The Journal of Portfolio Management 26 (3): 50–60.
- 【4】Banz, R. W. 1981. "The Relationship between Return and Market Value of Common Stocks." Journal of Financial Economics 9 (1): 3–18.
- 【5】Barber, B. M., and J. D. Lyon. 1997. "Firm Size, Book-to-Market Ratio, and Security Returns: A Holdout Sample of Financial Firms." The Journal of Finance 52 (2): 875–883.
- 【6】Barrett, G.F. and Donald, S.G., Consistent tests for stochastic dominance. Econometrica, 2003, 71, 71–104.
- 【7】Barberis, N., and A. Shleifer. 2003. "Style Investing." Journal of Financial Economics 68 (2): 161–199.
- 【8】Bauer, E., and R. Kohavi. 1999. "An Empirical Comparison of Voting Classification Algorithms: Bagging, Boosting, and Variants." Machine Learning 36: 105–139.
- 【9】Bauer, R., J. Derwall, and R. Molenaar. 2004. "The Real-Time Predictability of the Size and Value Premium in Japan." Pacific-Basin Finance Journal 12 (5): 503–523.
- 【10】Bird, R., and L. Casavecchia. 2011. "Conditional Style Rotation Model on Enhanced Value and Growth Portfolios: The European Experience." The Journal of Asset Management 11 (6): 375–390.
- 【11】Black, A. J., B. Mao, and D. G. McMillan. 2009. "The Value Premium and Economic Activity: LongRun Evidence from the United States." The Journal of Asset Management 10 (5): 305–317.
- 【12】Breiman, L. 1996. "Bagging Predictors." Machine Learning 24 (2): 123–140. ———. 2001. "Random Forests." Machine Learning 45 (1): 5–32.
- 【13】Breiman, L., J. Friedman, C. J. Stone, and R. A. Olshen. Classification and Regression Trees. Boca Raton, FL: CRC Press, 1984.
- 【14】Chan, L. K., J. Karceski, and J. Lakonishok. 2000. "New Paradigm or Same Old Hype in Equity Investing?" Financial Analysts Journal 56 (4): 23–36.
- 【15】Cooper, M. J., H. Gulen, and M. Vassalou. 2001. "Investing in Size and Book-to-Market Portfolios Using Information about the Macroeconomy: Some New Trading Rules." Mimeo, New York: Columbia University, 2001.
- 【16】Copeland, M. M., and T. E. Copeland. 1999. "Market Timing: Style and Size Rotation Using the VIX." Financial Analysts Journal 55 (2): 73–81.
- 【17】Daniel, K., and S. Titman. 1997. "Evidence on the Characteristics of Cross Sectional Variation in Stock Returns." The Journal of Finance 52 (1): 1–33.
- 【18】Dimson, E., S. Nagel, and G. Quigley. 2003. "Capturing the Value Premium in the United Kingdom." Financial Analysts Journal 59 (6): 35–45.
- 【19】Domingos, P., and M. Pazzani. 1996. "Beyond Independence: Conditions for the Optimality of the Simple Bayesian Classifier?" In Proceedings of the 13th International Conference on Machine Learning, pp. 105–112.
- 【20】Efremidze, L., J. A. DiLellio, and D. J. Stanley. 2014. Using VIX entropy indicators for style rotation timing. The Journal of Investing 23 (3): 130–143.
- 【21】Fama, E. F., and K. R. French. 1992. "The Cross-Section of Expected Stock Returns." The Journal of Finance 47 (2): 427–465.
- 【22】———. 1993. "Common Risk Factors in the Returns on Stocks and Bonds." Journal of Financial Economics 33 (1): 3–56.
- 【23】———. 1998. "Value versus Growth: The International Evidence." The Journal of Finance 53 (6): 1975–1999.
- 【24】———. 2015. "A Five-Factor Asset Pricing Model." Journal of Financial Economics 116 (1): 1–22.
- 【25】Frazzini, A., and L. H. Pedersen. 2014. "Betting against Beta." Journal of Financial Economics 111 (1): 1–25.
- 【26】Freund, Y., and R. E. Schapire. 1997. "A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting." Journal of Computer and System Sciences 55 (1): 119–139.
- 【27】Friedman, J. H. 1989. "Regularized Discriminant Analysis." Journal of the American

- Statistical Association 84 (405): 165–175.
- 【28】——. 2001. “Greedy Function Approximation: A Gradient Boosting Machine.” *Annals of Statistics* 29 (5): 1189–1232.
- 【29】——. 2002. “Stochastic Gradient Boosting.” *Computational Statistics & Data Analysis* 38 (4): 367–378.
- 【30】Gelman, A., A. Jakulin, M. G. Pittau, and Y.-S. Su. 2008. “A Weakly Informative Default Prior Distribution for Logistic and Other Regression Models.” *Annals of Applied Statistics* 2 (4): 1360–1383.
- 【31】Golosov, E., and S. Satchell. 2014. “Modeling Style Rotation: Switching and Re-Switching.” *Journal of Time Series Econometrics* 6 (2): 103–128.
- 【32】Gu, S., B. Kelly, and D. Xiu. 2020. “Empirical Asset Pricing via Machine Learning.” *The Review of Financial Studies* 33 (5): 2223–2273.
- 【33】Hoerl, A. E., and R. W. Kennard. 1970. “Ridge Regression: Applications to Nonorthogonal Problems.” *Technometrics* 12 (1): 69–82.
- 【34】Hossin, M., and M. Sulaiman. 2015. “A Review on Evaluation Metrics for Data Classification Evaluations.” *International Journal of Data Mining & Knowledge Management Process* 5 (2): 1.
- 【35】Iworiso, J., and S. Vrontos. 2020. “On the Directional Predictability of Equity Premium Using Machine Learning Techniques.” *Journal of Forecasting* 39 (3): 449–469.
- 【36】Jacobs, B. I., and K. N. Levy. 1996. “High Definition Style Rotation.” *Journal of Investing* 5 (3): 14–23.
- 【37】James, G., D. Witten, T. Hastie, and R. Tibshirani. “Statistical Learning.” In *An Introduction to Statistical Learning*, pp. 15–57. New York: Springer, 2013.
- 【38】Jensen, G. R., J. M. Mercer, and R. R. Johnson. 1996. “Business Conditions, Monetary Policy, and Expected Security Returns.” *Journal of Financial Economics* 40 (2): 213–237.
- 【39】Kao, D.-L., and R. D. Shumaker. 1999. “Equity Style Timing (Corrected).” *Financial Analysts Journal* 55 (1): 37–48.
- 【40】La Porta, R. 1996. “Expectations and the Cross-Section of Stock Returns.” *The Journal of Finance* 51 (5): 1715–1742.
- 【41】Lakonishok, J., A. Shleifer, and R. W. Vishny. 1994. “Contrarian Investment, Extrapolation, and Risk.” *The Journal of Finance* 49 (5): 1541–1578.
- 【42】Levis, M., and M. Liodakis. 1999. “The Profitability of Style Rotation Strategies in the United Kingdom.” *The Journal of Portfolio Management* 26 (1): 73–86.
- 【43】Lewellen, J. 1999. “The Time-Series Relations among Expected Return, Risk, and Book-to-Market.” *Journal of Financial Economics* 54 (1): 5–43.
- 【44】Liew, J., and M. Vassalou. 2000. “Can Book-to-Market, Size and Momentum Be Risk Factors That Predict Economic Growth?” *Journal of Financial Economics* 57 (2): 221–245.
- 【45】Lo, A. W., and A. C. MacKinlay. 1990. “Data-Snooping Biases in Tests of Financial Asset Pricing Models.” *The Review of Financial Studies* 3 (3): 431–467.
- 【46】Lucas, A., R. van Dijk, and T. Kloek. 2002. “Stock Selection, Style Rotation, and Risk.” *Journal of Empirical Finance* 9 (1): 1–34.
- 【47】MacKinlay, A. C. 1995. “Distinguishing among Asset Pricing Theories: An Ex Ante Analysis.” *Journal of Financial Economics* 38: 3–28.
- 【48】Nalbantov, G., R. Bauer, and I. Sprinkhuizen-Kuyper. 2006. “Equity Style Timing Using Support Vector Regressions.” *Applied Financial Economics* 16 (15): 1095–1111.
- 【49】Pesaran, M. H., and A. Timmermann. 1992. “A Simple Nonparametric Test of Predictive Performance.” *Journal of Business & Economic Statistics* 10 (4): 461–465.
- 【50】Schwarz, G. 1978. “Estimating the Dimension of a Model.” *Annals of Statistics* 6 (2): 461–464.
- 【51】Sokolova, M., and G. Lapalme. 2009. “A Systematic Analysis of Performance Measures for Classification Tasks.” *Information Processing & Management* 45 (4): 427–437.
- 【52】Tharwat, A. “Classification Assessment Methods.” *Applied Computing and Informatics*, 2020, <https://www.emerald.com/insight/content/doi/10.1016/j.aci.2018.08.003/full/html>.
- 【53】Tibshirani, R. 1996. “Regression Shrinkage and Selection via the LASSO.” *Journal of the Royal Statistical Society: Series B (Methodological)* 58 (1): 267–288.
- 【54】Vrontos, S. D., J. Galakis, and I. D. Vrontos. 2021. “Modeling and Predicting US Recessions Using Machine Learning Techniques.” *International Journal of Forecasting* 37 (2): 647–671.
- 【55】Wang, K. Q. 2005. “Style Rotation, Momentum and Multifactor Analysis.” *Journal of Financial and Quantitative Analysis* 40: 349–372.
- 【56】Zou, H., and T. Hastie. 2005. “Regularization and Variable Selection via the Elastic Net.” *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 67 (2): 301–320.

## 分析师声明

本人具有中国证券业协会授予的证券投资咨询执业资格并注册为证券分析师，以勤勉的职业态度，独立、客观地出具本报告。本报告清晰准确地反映了本人的研究观点。本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

## 投资评级说明

投资建议的评级标准	类别	评级	说明
报告中投资建议所涉及的评级分为股票评级和行业评级（另有说明的除外）。评级标准为报告发布日后的12个月内公司股价（或行业指数）相对同期相关证券市场代表性指数的涨跌幅。其中：A股市场以上证综指或深圳成指为基准，香港市场以恒生指数为基准；美国市场以标普500或纳斯达克综合指数为基准。	股票评级	买入	相对同期相关证券市场代表性指数涨幅大于15%
		审慎增持	相对同期相关证券市场代表性指数涨幅在5%~15%之间
		中性	相对同期相关证券市场代表性指数涨幅在-5%~5%之间
		减持	相对同期相关证券市场代表性指数涨幅小于-5%
		无评级	由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级
	行业评级	推荐	相对表现优于同期相关证券市场代表性指数
		中性	相对表现与同期相关证券市场代表性指数持平
		回避	相对表现弱于同期相关证券市场代表性指数

## 信息披露

本公司在知晓的范围内履行信息披露义务。客户可登录 [www.xyzq.com.cn](http://www.xyzq.com.cn) 内幕交易防控栏内查询静默期安排和关联公司持股情况。

## 使用本研究报告的风险提示及法律声明

兴业证券股份有限公司经中国证券监督管理委员会批准，已具备证券投资咨询业务资格。

，本公司不会因接收人收到本报告而视其为客户。本报告中的信息、意见等均仅供客户参考，不构成所述证券买卖的出价或征价邀请或要约。该等信息、意见并未考虑到获取本报告人员的具体投资目的、财务状况以及特定需求，在任何时候均不构成对任何人的个人推荐。客户应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求，必要时就法律、商业、财务、税收等方面咨询专家的意见。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本报告所载资料的来源被认为是可靠的，但本公司不保证其准确性或完整性，也不保证所包含的信息和建议不会发生任何变更。本公司并不对使用本报告所包含的材料产生的任何直接或间接损失或与此相关的其他任何损失承担任何责任。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的的价格、价值及投资收入可升可跌，过往表现不应作为日后的表现依据；在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告；本公司不保证本报告所含信息保持在最新状态。同时，本公司对本报告所含信息可在不发出通知的情形下做出修改，投资者应当自行关注相应的更新或修改。

除非另行说明，本报告中所引用的关于业绩的数据代表过往表现。过往的业绩表现亦不应作为日后回报的预示。我们不承诺也不保证，任何所预示的回报会得以实现。分析中所做的回报预测可能是基于相应的假设。任何假设的变化可能会显著地影响所预测的回报。

本公司的销售人员、交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理部门、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告并非针对或意图发送予或为任何就发送、发布、可得到或使用此报告而使兴业证券股份有限公司及其关联子公司等违反当地的法律或法规或可致使兴业证券股份有限公司受制于相关法律或法规的任何地区、国家或其他管辖区域的公民或居民，包括但不限于美国及美国公民（1934年美国《证券交易所》第15a-6条例定义为本「主要美国机构投资者」除外）。

本报告的版权归本公司所有。本公司对本报告保留一切权利。除非另有书面显示，否则本报告中的所有材料的版权均属本公司。未经本公司事先书面授权，本报告的任何部分均不得以任何方式制作任何形式的拷贝、复印件或复制品，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。未经授权的转载，本公司不承担任何转载责任。

## 特别声明

在法律许可的情况下，兴业证券股份有限公司可能会利差本报告中提及公司所发行的证券头寸并进行交易，也可能为这些公司提供或争取提供投资银行业务服务。因此，投资者应当考虑到兴业证券股份有限公司及/或其相关人员可能存在影响本报告观点客观性的潜在利益冲突。投资者请勿将本报告视为投资或其他决定的唯一信赖依据。

## 兴业证券研究

上海	北京	深圳
地址：上海浦东新区长柳路36号兴业证券大厦15层	地址：北京西城区锦什坊街35号北楼601-605	地址：深圳市福田区皇岗路5001号深业上城T2座52楼
邮编：200135	邮编：100033	邮编：518035
邮箱：research@xyzq.com.cn	邮箱：research@xyzq.com.cn	邮箱：research@xyzq.com.cn

请务必阅读正文之后的信息披露和重要声明

- 24 -